

LAPORAN TEKNIS DATA SCIENCE

MyFinance - Aplikasi Pencatatan Keuangan Berbasis AI

Coding Camp 2026 powered by DBS Foundation

CC26-PSU154

Informasi	Keterangan
Nama Proyek	MyFinance - Aplikasi Pencatatan Keuangan berbasis AI
Tema	Revolusi Teknologi Keuangan (Fintech) untuk Generasi Muda
Learning Path	Data Scientist
Penyusun	Nabiel Alfallah Herdiana (CDCC011D6Y2246) Pascal Zufar Hanif (CDCC011D6Y2151)
Tanggal	18 Mei 2026
Repository utama DS	MyFinance-Data

Dokumen ini berfungsi sebagai bukti teknis pekerjaan Data Science: pengumpulan data, data wrangling, EDA, feature engineering, dataset final, dashboard insight, dan rancangan integrasi output analitik MyFinance.

Daftar Isi

- Daftar Isi.....2
- 1. Ringkasan Eksekutif.....3
- 2. Latar Belakang dan Tujuan Data Science.....3
- 3. Business Questions.....4
- 4. Scope Pekerjaan Data Science.....4
- 5. Dataset dan Sumber Data.....5
- 6. Data Wrangling Pipeline.....5
- 7. Data Quality Assessment.....6
- 8. Dataset Final dan Data Dictionary.....7
 - 8.1 Dataset Final.....7
 - 8.2 Kolom Utama Dataset Master.....8
- 9. Exploratory Data Analysis.....8
 - 9.1 Distribusi Macro Category.....8
 - 9.2 Distribusi Master Category.....9
 - 9.3 Distribusi Source Data.....10
 - 9.4 Kualitas Label dan Missing Price.....10
 - 9.5 Analisis Harga per Kategori.....11
 - 9.6 Produk Mahal, Komposisi Source, dan Price Bin.....13
 - 9.7 Word Cloud Nama Produk.....14
- 10. Feature Engineering.....15
- 11. Modeling dan Analytical Logic.....15
 - 11.1 Auto-Categorization Dataset.....15
 - 11.2 Budget Protection / Cashflow Prediction.....16
 - 11.3 Financial Health Score.....16
 - 11.4 Smart Money Leak Detection.....17
- 12. Dashboard Streamlit.....18
- 13. Evaluasi, Limitasi, dan Risiko.....18
 - 13.1 Evaluasi Dataset.....18
 - 13.2 Limitasi Saat Ini.....18
 - 13.3 Risiko dan Mitigasi.....18
- 14. A/B Testing Synthetic Evaluation.....19
- 15. API Contract dan Integrasi.....20
- 16. Kesimpulan dan Rekomendasi.....21
- Lampiran A. Data Dictionary.....23

1. Ringkasan Eksekutif

MyFinance adalah aplikasi pencatatan keuangan berbasis AI yang dirancang untuk membantu pengguna muda mencatat transaksi, memahami pola pengeluaran, dan mendapatkan insight kondisi finansial secara lebih objektif. Pekerjaan Data Science pada proyek ini berfokus pada fondasi data dan analitik: pengumpulan data produk/transaksi, data wrangling, exploratory data analysis, feature engineering, penyusunan dataset final, serta perancangan insight seperti Financial Health Score, budget usage, overbudget risk, cashflow prediction, dan smart money leak detection.

Pipeline Data Science menghasilkan master dataset sebanyak 12.429 baris dan 19 kolom. Dari dataset tersebut dibuat dataset AI-ready sebanyak 12.429 baris dan 8 kolom untuk kebutuhan auto-categorization. Untuk analisis harga, dibuat price-only dataset sebanyak 10.969 baris. Selama proses cleaning, 733 baris atau sekitar 5,6% dari raw data dikeluarkan karena kualitas nama produk atau noise kategori tidak memenuhi kriteria dataset final.

2. Latar Belakang dan Tujuan Data Science

Masalah utama yang ingin diselesaikan adalah rendahnya konsistensi pengguna dalam mencatat pengeluaran dan sulitnya memahami kondisi finansial hanya dari daftar transaksi. Pencatatan manual sering berhenti pada aktivitas input, sementara pengguna tetap belum mengetahui apakah pola pengeluarannya sehat, berisiko, atau mengandung kebocoran kecil yang berulang.

Peran Data Science adalah mengubah data transaksi menjadi insight yang actionable. Oleh karena itu, pekerjaan DS tidak hanya berhenti pada pembersihan dataset, tetapi juga memastikan data siap dipakai untuk model, dashboard, dan fitur analitik aplikasi.

- Menyediakan dataset transaksi/produk yang bersih dan konsisten untuk training serta analisis.
- Mendesain kategori finansial yang relevan dengan pengguna muda: NEEDS, WANTS, dan OTHERS.
- Menyediakan insight dari EDA untuk memahami komposisi pengeluaran, rentang harga, kualitas data, dan potensi imbalance kategori.
- Menyusun analytical logic untuk Financial Health Score, Budget Usage, Overbudget Risk, Cashflow Prediction, dan Smart Money Leak Detection.
- Menyediakan dashboard analitik sebagai media eksplorasi hasil DS dan bukti visual untuk evaluasi proyek.

3. Business Questions

Pertanyaan bisnis yang menjadi dasar pekerjaan Data Science:

1. Kategori pengeluaran apa yang paling dominan pada dataset MyFinance?
2. Bagaimana distribusi NEEDS, WANTS, dan OTHERS dalam data transaksi/produk?
3. Source data mana yang paling banyak berkontribusi terhadap dataset final?
4. Bagaimana kualitas data harga dan label setelah proses cleaning?
5. Kategori apa yang memiliki median harga tertinggi dan berpotensi memengaruhi pola pengeluaran?
6. Fitur apa saja yang dapat membantu model auto-categorization memahami karakteristik produk/transaksi?
7. Bagaimana sistem dapat mendeteksi potensi money leak dari transaksi kecil yang berulang?
8. Bagaimana output DS dapat dikemas agar mudah dipakai oleh backend, frontend, dan dashboard?

4. Scope Pekerjaan Data Science

Area	Cakupan	Output
Data Gathering	Mengumpulkan data dari beberapa sumber produk/transaksi	Raw dataset per source
Data Assessing	Menilai struktur kolom, missing value, noise, duplikasi, dan validitas harga	Data quality notes dan removed rows audit
Data Cleaning	Normalisasi nama produk, harga, kategori, dan filtering noise	Master dataset
Labeling	Mapping raw category menjadi Macro_Category dan Master_Category	Label kategori final
Feature Engineering	Membuat fitur teks, harga, ukuran, dan readiness flag	Fitur dataset final
EDA	Menganalisis kategori, source, price, missing values, dan word cloud	PNG visualisasi dan insight

Dashboard	Menyajikan financial overview, health score, leak, budget, weekly rewind	Streamlit dashboard prototype
Integrasi	Mendefinisikan request/response untuk output DS	DS API contract

5. Dataset dan Sumber Data

Dataset disusun dari beberapa source yang merepresentasikan kebutuhan harian, transaksi makanan/minuman, aktivitas nongkrong, serta tambahan kategori. Setiap source memiliki struktur awal yang berbeda sehingga diperlukan proses standardisasi kolom dan mapping kategori.

Source	Rows	Unique products	Valid price rows	Missing price rows	Median price
alfagift	8.636	8.588	7.359	1.277	Rp19.500
hangout_treats	3.610	3.161	3.610	0	Rp20.000
tokopedia	164	164	0	164	-
additional	19	19	0	19	-

Source terbesar adalah alfagift dengan 8.636 baris atau sekitar 69,5% dari dataset final. Source hangout_treats menjadi kontributor terbesar kedua dengan 3.610 baris.

6. Data Wrangling Pipeline

Pipeline Data Science MyFinance mengikuti alur berikut:

9. Membaca data dari seluruh source kandidat, termasuk Alfagift, Tokopedia, hangout treats, dan additional data.
10. Menormalisasi nama kolom agar seluruh source memiliki struktur umum yang sama.
11. Membersihkan teks produk menjadi product_clean menggunakan lowercasing, trimming, penghapusan noise, dan normalisasi karakter.
12. Mengonversi harga ke format numerik dan membuat flag price_missing serta has_price.
13. Melakukan mapping raw category/raw subcategory menjadi raw_category_refined, Master_Category, dan Macro_Category.
14. Menjalankan filtering untuk menghapus bad product name dan noise yang tidak relevan.

15. Membuat engineered features seperti price_bin, name_length, word_count, contains_number, size_value, dan size_unit.
16. Mengekspor master dataset, AI-ready dataset, price-only dataset, summary table, removed rows audit, dan visualisasi EDA.

Tahap	Input	Output
Gathering	CSV/source hasil scrape	df_raw
Cleaning	df_raw	product_clean, price numeric, normalized category
Filtering	cleaned data	df_master dan removed_rows_audit
Feature Engineering	df_master	price_bin, name_length, word_count, contains_number, size_value, size_unit
Export	df_master + summary	dataset final dan figures

7. Data Quality Assessment

Dari total estimasi raw data 13.162 baris, pipeline mempertahankan 12.429 baris sebagai dataset final dan menghapus 733 baris. Alasan penghapusan paling besar adalah bad_product_name sebanyak 707 baris.

Metric	Nilai	Keterangan
Total raw rows estimated	13.162	Master final + removed rows audit
Final master rows	12.429	Data yang lolos filtering
Removed rows	733 (5,6%)	Baris yang tidak masuk dataset final
Valid price rows	10.969	Data dengan harga valid
Missing price rows	1.460 (11,7%)	Data tanpa harga valid
Duplicate product_clean	497	Duplikasi nama produk setelah cleaning
Label confidence high	12.429	Seluruh label final bernilai high
Drop reason	Jumlah rows	

bad_product_name	707
hangout_noise_food_home_meal	26

8. Dataset Final dan Data Dictionary

8.1 Dataset Final

Dataset	Rows	Columns	Kegunaan
myfinance_sprint1_master_dataset.csv	12.429	19	Dataset master setelah cleaning, labeling, dan feature engineering
myfinance_ai_training_dataset.csv	12.429	8	Dataset ringkas untuk kebutuhan auto-categorization/modeling
myfinance_price_only_dataset.csv	10.969	19	Dataset subset yang hanya memuat harga valid untuk analisis harga
summary_by_master_category.csv	7	11	Ringkasan per kategori utama
summary_by_source.csv	4	9	Ringkasan per source data
removed_rows_audit.csv	733	12	Audit baris yang dihapus dari dataset final

8.2 Kolom Utama Dataset Master


Dataset master memiliki 19 kolom. Kolom penting dibagi menjadi metadata, raw features, engineered features, label/target, dan flag kualitas data.

9. Exploratory Data Analysis

9.1 Distribusi Macro Category

Macro Category	Rows	Persentase
WANTS	6.880	55,4%
NEEDS	4.904	39,5%
OTHERS	645	5,2%

Proporsi Macro Category




Gambar 1. Distribusi Macro Category pada dataset final.

Insight: dataset didominasi oleh WANTS, disusul NEEDS dan OTHERS. Kondisi ini penting untuk diperhatikan karena model kategorisasi dan insight pengeluaran harus tetap robust terhadap ketidakseimbangan kategori.

9.2 Distribusi Master Category


Master Category	Rows	Persentase
Jajan & Nongkrong	5.637	45,4%
Kebutuhan Rumah & Mandi	2.411	19,4%
Makan & Minum Harian	2.369	19,1%
Hobi & Self-Reward	1.243	10,0%
Lain-lain & Darurat	645	5,2%
Transportasi & Rutinitas	81	0,7%
Tagihan & Kewajiban	43	0,3%



Gambar 2. Distribusi Master Category.

Insight: kategori Jajan & Nongkrong menjadi kategori paling dominan. Hal ini relevan dengan problem statement MyFinance karena pengeluaran kecil berulang pada kategori nongkrong/jajan dapat menjadi sumber money leak.


9.3 Distribusi Source Data




Gambar 3. Distribusi source data.

Insight: Alfagift mendominasi dataset, sehingga kategori kebutuhan rumah, mandi, makanan, dan produk sehari-hari cenderung lebih banyak terwakili. Hangout_treats menambah coverage untuk kebutuhan lifestyle, jajan, dan nongkrong.

9.4 Kualitas Label dan Missing Price




Gambar 4. Distribusi label confidence.




Gambar 5. Missing price berdasarkan source.

Insight: semua label final berada pada confidence high. Namun, terdapat 1.460 row atau 11,7% dataset final yang belum memiliki harga valid. Karena itu, analisis harga dilakukan menggunakan price-only dataset agar hasil statistik harga tidak bias oleh missing values.

9.5 Analisis Harga per Kategori



Gambar 6. Sebaran harga per Master Category.




Gambar 7. Median harga per Master Category.

Macro	Master	Rows	Valid price	Median	Mean
WANTS	Jajan & Nongkrong	5.637	5.295	Rp16.000	Rp24.886


NEEDS	Kebutuhan Rumah & Mandi	2.411	2.253	Rp26.500	Rp34.138
NEEDS	Makan & Minum Harian	2.369	1.803	Rp16.500	Rp39.723
WANTS	Hobi & Self-Reward	1.243	989	Rp36.900	Rp51.278
OTHERS	Lain-lain & Darurat	645	562	Rp17.500	Rp28.259
NEEDS	Transportasi & Rutinitas	81	67	Rp26.900	Rp29.427
NEEDS	Tagihan & Kewajiban	43	0	-	-

Insight: Hobi & Self-Reward memiliki median harga tertinggi, sedangkan Jajan & Nongkrong adalah kategori paling dominan secara jumlah. Kombinasi frekuensi tinggi dan nominal kecil-menengah ini penting untuk fitur money leak detection.


9.6 Produk Mahal, Komposisi Source, dan Price Bin



Gambar 8. Top 20 produk dengan harga tertinggi.




Gambar 9. Komposisi Master Category per source.



Gambar 10. Distribusi price bin.

Insight: sebagian besar harga berada pada rentang 10k-25k dan 25k-50k. Rentang ini sesuai dengan pola pengeluaran harian pengguna muda, seperti makanan, minuman, snack, dan kebutuhan kecil yang berulang.

9.7 Word Cloud Nama Produk



Gambar 11. Word cloud dari product_clean.

Insight: kata-kata dominan pada product_clean dapat membantu model text classification mengenali pola kategori. Nama produk menjadi fitur utama karena mengandung sinyal semantik seperti kopi, susu, snack, sabun, shampoo, tiket, atau produk lifestyle.

10. Feature Engineering

Feature engineering dilakukan untuk memperkaya dataset agar siap digunakan dalam analisis dan modeling.

Feature	Deskripsi	Kegunaan
product_clean	Teks nama produk yang sudah dinormalisasi	Fitur utama untuk auto-categorization
price	Harga numerik	Fitur numerik untuk analisis dan model
price_missing / has_price	Flag kelengkapan harga	Data quality dan filtering
price_bin	Kelompok rentang harga	EDA dan potensi fitur kategorikal
name_length	Panjang karakter product_clean	Fitur teks sederhana
word_count	Jumlah kata product_clean	Fitur teks sederhana
contains_number	Apakah nama produk mengandung angka	Menangkap ukuran/volume/varian produk
size_value	Nilai ukuran jika terdeteksi	Fitur ukuran produk
size_unit	Satuan ukuran, seperti ml/g/kg/pcs	Fitur ukuran produk
is_ai_ready	Flag kesiapan data untuk model	Filter readiness untuk AI/modeling

Catatan anti data leakage: kolom target seperti Master_Category dan Macro_Category tidak boleh dipakai sebagai fitur input ketika model bertujuan memprediksi kategori. Kolom label_confidence dan raw_category_refined juga perlu diperlakukan hati-hati karena dapat membawa informasi turunan dari proses labeling.

11. Modeling dan Analytical Logic

11.1 Auto-Categorization Dataset

Dataset AI-ready disusun untuk mendukung model auto-categorization. Dataset ini berisi product_clean, price, price_missing, raw_category_refined, Macro_Category, Master_Category, label_confidence, dan source. Target utama yang direkomendasikan adalah Master_Category, sedangkan Macro_Category dapat dipakai untuk level klasifikasi yang lebih umum.

Target	Keterangan
Master_Category	Target utama untuk klasifikasi kategori detail, misalnya Jajan & Nongkrong, Makan & Minum Harian, Kebutuhan Rumah & Mandi.
Macro_Category	Target tingkat tinggi untuk klasifikasi NEEDS, WANTS, dan OTHERS.

11.2 Budget Protection / Cashflow Prediction

Repo DS memuat model budget protection berbasis RandomForestRegressor. Model menggunakan fitur kalender dan histori spending seperti day_of_week, day_of_month, is_weekend, is_payday, is_month_start, is_month_end, amount_lag_1, amount_lag_7, rolling_mean_7, dan rolling_sum_7. Model dilatih per master category untuk memprediksi actual spend harian.

Komponen	Isi
Model	RandomForestRegressor
Training data	df_features.csv / myfinance_daily_features_ready.csv
Target	actual_spend = transaction_count * avg_transaction_amount
Granularity	Daily per master_category
Output artifact	model/category_model/<category> category model.joblib

11.3 Financial Health Score

Prototype dashboard menghitung financial health berdasarkan cashflow dan savings rate. Dalam implementasi lanjutan, skor disarankan digabungkan dengan indikator budget adherence, needs/wants ratio, jumlah kategori overbudget, leak count, dan stabilitas cashflow agar lebih representatif terhadap kondisi keuangan pengguna.

Indikator	Definisi	Interpretasi
Net cashflow	Total income dikurangi total expense	Positif berarti cashflow sehat
Savings rate	Net cashflow / total income	Semakin tinggi semakin baik

Needs ratio	NEEDS spending / income	Menggambarkan beban kebutuhan utama
Wants ratio	WANTS spending / income	Menggambarkan konsumsi discretionary
Budget used ratio	Actual spending / budget limit	Mendeteksi tekanan terhadap budget
Overbudget count	Jumlah kategori dengan spending melewati limit	Indikator risiko budget
Leak count	Jumlah item/frekuensi pengeluaran kecil berulang	Indikator money leak

11.4 Smart Money Leak Detection

Money leak detection bertujuan mendeteksi pengeluaran kecil yang terjadi berulang dan dapat membesar secara kumulatif. Prototype dashboard mendeteksi leak dari transaksi kategori WANTS/OTHERS yang memiliki frekuensi lebih dari dua kali. Output yang disajikan meliputi nama item, kategori, frekuensi, total spending, rule leak type, dan final potential leak flag.

Rule	Penjelasan
Candidate category	Transaksi kategori WANTS dan OTHERS lebih diprioritaskan sebagai kandidat leak
Frequency rule	Item yang muncul lebih dari dua kali ditandai sebagai potential leak
Total spending rank	Leak diurutkan berdasarkan total spending untuk menentukan prioritas perhatian
Final flag	is_final_potential_leak digunakan untuk menandai item yang harus ditampilkan sebagai warning

12. Dashboard Streamlit

Dashboard Streamlit disiapkan untuk menampilkan hasil analitik Data Science dalam bentuk yang mudah dipahami. File utama dashboard adalah app.py dan utils.py, dengan data terkoneksi dengan API pada deployment utama.

Menu Dashboard	Fungsi
Dashboard	Menampilkan financial overview, health score, AI insight, dan metric breakdown
Leak Detection	Menampilkan tabel item yang berpotensi menjadi money leak
Budget & Risk	Menampilkan budget usage, risk level, daily spending trend, dan recent transactions
Weekly Rewind	Menampilkan ringkasan income, expense, net cashflow, top category, top leak item, dan weekly insight

13. Evaluasi, Limitasi, dan Risiko

13.1 Evaluasi Dataset

- Dataset final mempertahankan 12.429 row dari estimasi 13.162 raw row.
- Sebanyak 733 row dikeluarkan dengan audit reason yang terdokumentasi.
- Seluruh label final memiliki label_confidence high.
- 10.969 row memiliki harga valid dan 1.460 row memiliki missing price.
- Dataset price-only dibuat agar analisis harga tidak bias oleh missing values.

13.2 Limitasi Saat Ini

- Distribusi kategori tidak seimbang; Jajan & Nongkrong jauh lebih dominan dibanding Transportasi & Rutinitas dan Tagihan & Kewajiban.
- Sebagian data tidak memiliki harga valid sehingga model/analisis yang membutuhkan harga harus menggunakan subset atau strategi imputasi yang hati-hati.
- Financial Health Score prototype masih sederhana dan sebaiknya diperluas menjadi weighted score multi-indikator.

13.3 Risiko dan Mitigasi

Risiko	Dampak	Mitigasi
Imbalance kategori	Model cenderung bias ke kategori dominan	Gunakan class weighting, stratified split, dan evaluasi macro-F1


Missing price	Analisis harga/prediksi budget bias	Gunakan price-only dataset atau imputasi yang terdokumentasi
Data leakage	Evaluasi model tampak tinggi tetapi tidak generalizable	Pisahkan target/metadata dari fitur training

14. A/B Testing Synthetic Evaluation

A/B Testing dilakukan menggunakan data sintesis untuk mendemonstrasikan metode evaluasi fitur AI auto-categorization. Eksperimen membandingkan Variant A, yaitu input kategori manual, dengan Variant B, yaitu input berbantuan AI auto-categorization.

Metrik yang dievaluasi meliputi completion time, transaction saved rate, category accuracy, number of corrections, dan satisfaction score. Hasil simulasi menunjukkan bahwa Variant B memiliki completion time lebih rendah, category accuracy lebih tinggi, jumlah koreksi lebih rendah, dan satisfaction score lebih baik dibandingkan Variant A.

Karena data yang digunakan bersifat sintesis, hasil eksperimen ini tidak diklaim sebagai validasi pengguna nyata. Eksperimen ini digunakan sebagai bukti implementasi metode evaluasi dan rencana pengujian lanjutan menggunakan data user nyata.



Gambar 12. Output A/B Testing

15. API Contract dan Integrasi

Output Data Science disiapkan agar dapat digunakan oleh backend, frontend, dan dashboard. Kontrak API ini mendefinisikan format request dan response untuk fitur analytical insight seperti Financial Health Score, overbudget risk, predicted cashflow, dan money leak detection. Terdapat 2 API yang digunakan pada dashboard yaitu Get Data API, dan Financial Score API.

15.1. Get Data API

Get Data API digunakan untuk mendapatkan data pengeluaran user pada periode tertentu, Get Data API memerlukan parameter `user_id`, `start_date`, dan `end_date`. Hasil dari GET Request tersebut adalah `user_id`, `month_period`, `start_date`, `end_date`, `transactions`, dan `transaction_items`.

Parameter

Parameter	Detail
<code>user_id</code>	ID unik yang dimiliki oleh setiap user yang menandakan user mana yang akan diambil datanya
<code>start_date</code>	Start date adalah parameter tanggal dalam bentuk “YYYY_MM_DD” untuk menandakan periode awal dari data yang diambil
<code>end_date</code>	End date adalah parameter tanggal dalam bentuk “YYYY_MM_DD” untuk menandakan periode akhir dari data yang diambil

Response

Key	Details
<code>user_id</code>	ID unik yang dimiliki oleh setiap user yang menandakan user mana yang telah diambil datanya
<code>month_period</code>	Month period dalam bentuk MM-YYYY untuk menandakan kapan periode data yang diambil
<code>start_date</code>	Start date adalah parameter tanggal dalam bentuk “YYYY_MM_DD” untuk menandakan periode awal dari data yang telah diambil
<code>end_date</code>	End date adalah parameter tanggal dalam bentuk “YYYY_MM_DD” untuk menandakan periode akhir dari data yang diambil

transactions	Transactions berisi data pada setiap transaksi yang dilakukan yang berisi id transaksi, wallet_id, tipe transaksi (INCOME/EXPENSE), total_amount, category (NEEDS/WANTS/OTHERS), subcategory, description, dan transaction_date
transaction_items	Transaction items berisi produk/items yang dibeli oleh user pada suatu transaksi, yang berisi id, transaction_id, item_name, price, category, dan subcategory

Endpoint:

`https://myfinance-backend-app.up.railway.app/api/v1/export/streamlit?USERID={user_id}&START={start_date}&END={end_date}`

Return Value

```
{
  "user_id": "cc3fd629-6e03-4b21-b6db-6e20f3d9dc39",
  "month_period": "2026-04",
  "start_date": "2026-04-01",
  "end_date": "2026-04-30",
  "transactions": [
    {
      "id": "c29a13da-8f73-4ebc-8fea-4c9d9a7e296e",
      "wallet_id": "ff95578f-97fd-4b07-925e-04b5242a232f",
      "type": "EXPENSE",
      "total_amount": 24500,
      "category": "NEEDS",
      "subcategory": "Makan & Minum Harian",
      "description": "Sarapan",
      "transaction_date": "2026-04-01"
    }
  ],
  "transaction_items": [
    {
      "id": "3bcl5d8a-ab67-428e-a3bd-ba455d615938",
      "transaction_id": "c29a13da-8f73-4ebc-8fea-4c9d9a7e296e",
      "item_name": "Sarapan",
      "price": 24500,
      "category": "NEEDS",
      "subcategory": "Makan & Minum Harian"
    }
  ]
}
```

15.2. Financial Score API

Financial Score API digunakan untuk mendapatkan hasil analisis dari data pengeluaran yang ada. Request yang diberikan adalah `user_id`, `month_period`, `start_date`, `end_date`, `transactions`, dan `transaction_items`. Response yang diberikan oleh API ini adalah `financial_score`, `score_category`, `total_income`, `total_expense`, `net_cashflow`, `savings_rate`, `needs_ratio`, `wants_ratio`, `others_ratio`, `final_potential_leak_count`, `final_potential_leak_spending`, `potential_leak_ratio`, `budget_used_ratio_total`, `overbudget_category_count`, `spending_volatility`, `score_reason`, dan `leak_products`

Request

Key	Details
<code>user_id</code>	ID unik yang dimiliki oleh setiap user yang menandakan user mana yang akan dianalisis
<code>month_period</code>	Month period dalam bentuk MM-YYYY untuk menandakan kapan periode data yang akan dianalisis
<code>start_date</code>	Start date adalah parameter tanggal dalam bentuk “YYYY_MM_DD” untuk menandakan periode awal dari data yang akan dianalisis
<code>end_date</code>	End date adalah parameter tanggal dalam bentuk “YYYY_MM_DD” untuk menandakan periode akhir dari data yang akan dianalisis
<code>transactions</code>	Transactions berisi data pada setiap transaksi yang dilakukan yang berisi id transaksi, <code>wallet_id</code> , tipe transaksi (INCOME/EXPENSE), <code>total_amount</code> , <code>category</code> (NEEDS/WANTS/OTHERS), <code>subcategory</code> , <code>description</code> , dan <code>transaction_date</code>
<code>transaction_items</code>	Transaction items berisi produk/items yang dibeli oleh user pada suatu transaksi, yang berisi id, <code>transaction_id</code> , <code>item_name</code> , <code>price</code> , <code>category</code> , dan <code>subcategory</code>

Response

Key	Details
<code>financial_score</code>	Financial score adalah score yang diberikan dari hasil analisis dari pola pengeluaran user berdasarkan kriteria tertentu
<code>score_category</code>	Score category diberikan berdasarkan skor <code>financial_score</code> yang didapatkan oleh user
<code>total_income</code>	Total income merupakan total dari seluruh

	penghasilan yang didapatkan oleh user
total_expense	Total dari seluruh pengeluaran yang dikeluarkan oleh user
net_cashflow	Bertambah atau berkurangnya arus kas dari total uang yang berada dalam wallet user
savings_rate	Persentase dari tabungan/uang yang tersisihkan dari penghasilan - pengeluaran
needs_ratio	Rasio dari pengeluaran berkategori needs dari total pengeluaran
wants_ratio	Rasio dari pengeluaran berkategori wants dari total pengeluaran
others_ratio	Rasio dari pengeluaran berkategori others dari total pengeluaran
final_potential_leak_count	Jumlah potensial leak dari pengeluaran user
final_potential_leak_spending	Jumlah uang yang dikeluarkan dari produk yang memiliki leak potential
potential_leak_ratio	Rasio leak pada pengeluaran user
budget_used_ratio_total	Rasio pengeluaran terhadap budget yang telah ditentukan
overbudget_category_count	Jumlah kategori yang sudah melewati batas budget yang ditentukan oleh user
spending_volatility	Pengukuran rasio volatilitas dari pengeluaran user
score_reason	Alasan dari financial_score yang didapatkan oleh user
leak_products	List produk-produk yang memiliki potensi sebagai suatu “leak”

Endpoint:

<https://myfinance.nya.je/api/v1/leak-and-financial-score>

Contoh Request:

```
{
  "user_id": "cc3fd629-6e03-4b21-b6db-6e20f3d9dc39",
  "month_period": "2026-04",
  "start_date": "2026-04-01",
  "end_date": "2026-04-30",
  "transactions": [
    {
```

```

      "id": "c29a13da-8f73-4ebc-8fea-4c9d9a7e296e",
      "wallet_id": "ff95578f-97fd-4b07-925e-04b5242a232f",
      "type": "EXPENSE",
      "total_amount": 24500,
      "category": "NEEDS",
      "subcategory": "Makan & Minum Harian",
      "description": "Sarapan",
      "transaction_date": "2026-04-01"
    }],
    "transaction_items": [
      {
        "id": "3bc15d8a-ab67-428e-a3bd-ba455d615938",
        "transaction_id": "c29a13da-8f73-4ebc-8fea-4c9d9a7e296e",
        "item_name": "Sarapan",
        "price": 24500,
        "category": "NEEDS",
        "subcategory": "Makan & Minum Harian"
      }
    ]
  }
}

```

Contoh Response:

```

{
  "financial summary": {
    "financial_score": 55,
    "score_category": "Fair",
    "total_income": 4993492,
    "total_expense": 5428228,
    "net_cashflow": -434736,
    "savings_rate": -0.08706051797019,
    "needs_ratio": 0.8540039217217847,
    "wants_ratio": 0.07245458370576918,
    "others_ratio": 0,
    "final_potential_leak_count": 1,
    "final_potential_leak_spending": 115000,
    "potential_leak_ratio": 0.02118555079116058,
    "budget_used_ratio_total": 0,
    "overbudget_category_count": 0,
    "spending_volatility": 1.9610038789816024,
    "score_reason": "Cashflow negatif karena pengeluaran lebih besar dari pemasukan. Terdapat beberapa potensi leak. Pengeluaran harian cukup fluktuatif."
  },
  "leak_products": [
    "chiffon coklat"
  ]
}

```

16. Kesimpulan dan Rekomendasi

Proses Data Science untuk aplikasi MyFinance telah berhasil membangun fondasi analitik dan data yang komprehensif, mencakup keseluruhan tahapan mulai dari pengumpulan data hingga perancangan integrasi untuk frontend dan backend. Pekerjaan ini menghasilkan tiga output dataset utama, yakni dataset master sebanyak 12.429 baris dan 19 kolom, dataset AI-ready dengan dimensi 12.429 baris dan 8 kolom, serta dataset price-only sebanyak 10.969 baris untuk kebutuhan analisis

harga. Selama tahapan pembersihan, tim juga mendokumentasikan penghapusan 733 baris data ke dalam removed rows audit guna menjaga transparansi keseluruhan proses.

Berdasarkan hasil Exploratory Data Analysis (EDA), kategori makro WANTS sangat mendominasi dengan porsi 55,4% dari dataset final. Pada tingkat yang lebih spesifik, Jajan & Nongkrong menjadi kategori utama penyumbang data terbesar dengan persentase 45,4%. Pengeluaran kecil dan berulang pada kategori inilah yang menjadi sorotan utama sebagai potensi kebocoran finansial (money leak) bagi pengguna muda. Analisis harga turut memperlihatkan bahwa mayoritas transaksi berada di rentang Rp10.000 hingga Rp50.000, dengan frekuensi tertinggi pada kategori jajan tersebut, sementara kategori Hobi & Self-Reward mencatatkan median harga paling tinggi. Temuan ini, dikombinasikan dengan pengayaan dataset melalui feature engineering yang dirancang khusus untuk menghindari data leakage, menjadi landasan yang kuat untuk pengembangan fitur Smart Money Leak Detection.

Output analitik yang dihasilkan telah mencakup rancangan fitur-fitur krusial seperti Financial Health Score, prediksi arus kas, fitur pengingat risiko overbudget, hingga deteksi kebocoran uang yang keseluruhannya divisualisasikan melalui purwarupa dashboard Streamlit. Selain itu, metode evaluasi untuk fitur kategorisasi otomatis (AI auto-categorization) juga telah berhasil divalidasi melalui simulasi A/B Testing menggunakan data sintetis. Meski demikian, sistem ini masih memiliki beberapa batasan yang perlu diperhatikan, seperti ketidakseimbangan distribusi pada kategori data, adanya sejumlah data yang tidak memiliki harga valid, indikator Financial Health Score yang masih bersifat sederhana, serta kebutuhan untuk mengintegrasikan output analitik ke sistem backend production.

Untuk mengatasi batasan yang ada dan memaksimalkan potensi analitik aplikasi, terdapat beberapa rekomendasi pengembangan lanjutan. Pertama, pengumpulan data perlu diperluas dan difokuskan pada kategori minoritas seperti Tagihan & Kewajiban serta Transportasi & Rutinitas untuk menyeimbangkan dataset. Dalam tahapan pemodelan, disarankan untuk menerapkan metode stratified split dan memantau metrik macro-F1 agar evaluasi model lebih tangguh terhadap ketimpangan data. Selanjutnya, perumusan Financial Health Score perlu ditingkatkan agar menjadi sistem weighted score multi-indikator yang lebih komprehensif, diiringi dengan penguatan aturan pendeteksian money leak berbasis histori transaksi nyata. Pada akhirnya, seluruh sistem analitik dan dashboard harus diintegrasikan sepenuhnya dengan backend production agar insight yang dihasilkan benar-benar merepresentasikan kondisi finansial riil dari pengguna MyFinance.

Lampiran A. Data Dictionary

Column	Type	Description	Role
source	string	Sumber data seperti alfabgift, hangout_treats, tokopedia, additional	Metadata
raw_category	string	Kategori awal dari sumber data	Raw feature
raw_subcategory	string	Subkategori awal dari sumber data	Raw feature
raw_category_refined	string	Kategori hasil refinement dari raw category/subcategory	Intermediate feature
product_name_raw	string	Nama produk asli sebelum cleaning	Raw feature
product_clean	string	Nama produk setelah normalisasi teks	Model feature
price	numeric	Harga produk/transaksi dalam Rupiah	Feature/analysis
price_missing	boolean	Penanda apakah harga kosong/tidak valid	Data quality feature
has_price	boolean	Penanda apakah harga valid tersedia	Data quality feature
price_bin	categorical	Rentang harga seperti 0-10k, 10k-25k, dst.	Engineered feature
name_length	integer	Panjang karakter product_clean	Engineered feature
word_count	integer	Jumlah kata product_clean	Engineered feature
contains_number	boolean	Penanda apakah product_clean mengandung angka	Engineered feature

size_value	numeric	Nilai ukuran produk jika terdeteksi	Engineered feature
size_unit	string	Satuan ukuran seperti ml, g, kg, pcs	Engineered feature
Macro_Category	string	Kategori makro: NEEDS, WANTS, OTHERS	Target/label
Master_Category	string	Kategori utama final	Target/label
label_confidence	string	Tingkat confidence label	Metadata
is_ai_ready	boolean	Flag data siap untuk kebutuhan AI/modeling	Filter flag